

房源图片模块 — 交付成员C

2026年7月1日 | 改动：胡霖 | 接收：成员C

一、改了什么

1. 数据库新增字段

houses 表新增 image_urls 列 (TEXT, 存 JSON 数组):

```
ALTER TABLE houses ADD COLUMN image_urls TEXT;
```

存储格式: ["https://image1.ljcdn.com/...", "https://image1.ljcdn.com/...", ...]

当前数据分布:

来源	总数	有图片	图片类型
lianjia	526	爬取中	真实房源照片
anjike	10,133	待爬取	真实房源照片
augmented	44,320	44,320 (100%)	SVG 占位图

2. API 新增字段

GET /api/houses 和 GET /api/houses/{id} 返回中增加了 image_urls :

```
{
  "id": 275109,
  "title": "万中后门口3房...",
  "total_price": 39.85,
  "image_urls": [
    "/api/images/placeholder/275109/0",
    "/api/images/placeholder/275109/1",
    "/api/images/placeholder/275109/2"
  ]
}
```

爬取真实图片后会完整 CDN URL：

```
{
  "image_urls": [
    "https://image1.ljcdn.com/110000-inspection/pc1_UqiPfvdg6.jpg",
    "https://image1.ljcdn.com/110000-inspection/pc0_QznXYz3Yb.jpg",
    "https://image1.ljcdn.com/hdic-resblock/4d68ac4c-a21b-4670-82c6-ed18c74bdfc1.jpg"
  ]
}
```

3. 新增占位图片接口

GET /api/images/placeholder/{house_id}/{index}

- 无需鉴权
- 返回 SVG 图片 (Content-Type: image/svg+xml)
- index : 0=蓝(客厅), 1=紫(卧室), 2=绿(外观)
- SVG 内含真实房源信息 (小区名、户型、面积、价格)

4. 新增图片爬虫脚本

文件： crawler/scrape_images.py

功能：

- 从链家/安居客详情页爬取真实房源照片
- 单线程慢爬，不用代理
- 支持断点续传 (已有图片的自动跳过)
- 需要浏览器 Cookie (已内置在文件顶部)

二、改动涉及的文件

文件	改动
backend/database.py	Decimal→float 类型转换器，_convert_decimals 辅助函数
backend/schemas.py	HouseItem 新增 image_urls: Optional[Any]
backend/routers/houses.py	查询加入 image_urls ，新增占位图接口，新增 _parse_image_urls
backend/main.py	json_encoders={Decimal: float} 兜底
crawler/scrape_images.py	新文件 — 图片爬虫（含 Cookie 配置）
docs/API接口文档_v2_实测版.md	新文件 — 全部接口实测文档
docs/素材_图片模块_交付成员C.md	本文件

三、Kotlin 端对接

```
data class HouseItem(  
    val id: Int,  
    val title: String?,  
    // ... 其他字段不变  
    val image_urls: List<String>? // 新增  
)
```

完整 URL 拼接：

```
// 占位图（所有 augmented 数据 + 未爬取的房源）  
"${BASE_URL}api/images/placeholder/$houseId/$index"  
  
// 真实图片（链家/安居客爬取后）  
image_urls[index] // 直接使用，已是完整 CDN URL
```

加载示例（Glide/Coil）：

```
// 如果图片以 /api/ 开头，拼 BASE_URL；否则直接用（CDN 地址）
fun resolveImageUrl(raw: String, baseUrl: String): String {
    return if (raw.startsWith("/api/")) baseUrl + raw.dropWhile { it == '/' }
    else raw
}
```

四、运行图片爬虫

前置条件

Cookie 已内置在 crawler/scrape_images.py 第 49-50 行。过期后从浏览器重新复制粘贴。

命令

```
cd D:\SWU\大二下\学年设计\chongqing-house-analysis
```

```
# 链家（526条，约40分钟）
```

```
python crawler/scrape_images.py --source lianjia
```

```
# 安居客（先试100条）
```

```
python crawler/scrape_images.py --source anjuke --limit 100
```

```
# 测试模式（不写数据库）
```

```
python crawler/scrape_images.py --source lianjia --limit 5 --dry-run
```

```
# 查看进度
```

```
python -c "from backend.database import query; r=query(\"SELECT source, COUNT(*) as cnt FROM hoi
```

注意事项

- 必须后端正在运行（爬虫直接写数据库）
- 爬虫单线程，每个房源间隔 3-8 秒
- 触发验证码自动等 30-60 秒
- Ctrl+C 中断后重跑即可续传
- Cookie 有效约几小时，过期需更新

五、附：Decimal 类型修复

今天同时修复了 MySQL DECIMAL 字段序列化为字符串的问题。之前返回值：

```
{ "total_price": "39.85", "area": "87.80" } // 字符串 ❌
```

修复后：

```
{ "total_price": 39.85, "area": 87.80 } // 数字 ✅
```

影响所有接口的数值字段（价格、面积等）。Kotlin Double 类型现在能正确解析。